

ASR 기초 공부_whisper

2026.02.09.
HyorinJung


Whisper 모델

- 다국어 지원: 영어를 포함한 **90개** 이상의 언어를 인식
- 강건성: 소음, 억양, 발음 차이에도 견고한 인식 성능
- 자동 번역 기능: 음성에서 다른 언어로 번역 가능
- 오픈소스 제공: 누구나 다운로드해 로컬 또는 서버에 설치 가능
- 다양한 모델 크기 제공: **tiny** → **base** → **small** → **medium** → **large**

전처리

- 최소 전처리
 - 전사 텍스트를 정규화하지 않고 **raw text** 그대로 예측
 - 역텍스트 정규화(이천이십육년 삼월 이일 오후 세 시 십오 분 → 2026년 3월 2일 오후 3시 15분) 단계 제거 → 파이프라인 단순화
- 데이터 특성
 - 인터넷 기반 (**audio, transcript**) 페어
 - 환경·화자·언어가 매우 다양한 대규모 데이터
 - 오디오 다양성은 긍정적, 전사 다양성(저품질)은 문제
- 전사 품질 필터링: 저품질 전사(기계가 만든 전사) 다수 발견 → 자동 필터링 기법 도입
 - 언어 일치 검증
 - 오디오 언어 vs 전사 언어 일치 여부 검사 → 불일치시 제외 # **CLD2** (Google Compact Language Detector)
 - 단, 영어 전사는 음성 번역(X→en) 데이터로 활용
 - 중복 제거
 - 전사 텍스트 기준 퍼지 중복(사실상 같은 텍스트) 제거
- 세그먼트 구성
 - 오디오를 30초 단위로 분할
 - 무음 구간도 포함 → VAD 학습 데이터(voice activity detection) # <|nospeech|>
- 사후 필터링
 - 초기 모델 오류율(**wer**) 기반 데이터 소스 분석
 - 수동 검토로 저품질·오정렬·잔여 기계 전사 제거
- 평가 데이터 오염 방지
 - 훈련-평가 데이터 간 전사 중복 제거
 - **TED-LIUM 3**를 주요 대상으로 처리(고위험군으로 간주)

Sequence-to-sequence learning



인코더 구조

- Conv stem:
 - Conv × 2
 - Kernel size = 3
 - Activation = GELU
 - 두 번째 Conv에 stride = 2
- Sinusoidal positional embedding
- Transformer encoder blocks
- Pre-activation residual blocks $y = x + \text{SubLayer}(\text{LN}(x))$
- Final layer norm

디코더 구조

- Learned positional embeddings
- put-output token embedding 공유
- 인코더와 동일한 width & depth

토큰나이저 전략

- 영어 모델: GPT-2 byte-level BPE(자주 등장하는 문자를 하나의 토큰으로) 그대로 사용
- 다국어 모델:
 - vocab size는 유지
 - 다국어에 맞게 vocabulary 재학습
 - 영어 편향으로 인한 과도한 분절 방지

멀티태스킹 셋업





Image Credit: 오리지널 논문

논문 제목	저자	학회	요약
AudioSAE: Towards Understanding of Audio-Processing Models with Sparse AutoEncoders	Georgii Aparin, Tasnima Sadekova, Alexey Rukhovich, Assel Yermekova, Laida Kushnareva, Vadim Popov, Kristian Kuznetsov, Irina Piontkovskaya	EACL 2026	Whisper와 HuBERT 전 층에 학습한 SAE는 안정적이고 해석 가능한 음성 표현을 학습하며, 개념 분리·제어·잡음 감소·뇌 신호와의 정렬까지 가능한 실용적 해석 도구임을 입증함.
Sparse Autoencoders Make Audio Foundation Models More Explainable	Théo Mariotte, Martin Lebourdais, Antonio Almudévar, Marie Tahon, Alfonso Ortega, Nicolas Dugué	ICASSP 2026	Sparse Autoencoder를 사용하면 오디오 사전학습 모델의 은닉 표현을 보다 구조적으로 분석할 수 있으며, 특히 노래 발성 기법과 같은 보컬 속성을 잘 분리·해석할 수 있어 표현에 내재된 핵심 요인을 드러내는 데 효과적임
DepressGEN: Synthetic Data Generation for Depression Detection	Wenrui Liang, Rong Zhang, Xuezhen Zhang, Ying Ma, Wei-Qiang Zhang	INTERSPEECH 2025	이 연구는 텍스트 → 음성 (TTS) 생성이 곧 우울증 모델 학습에 데이터 확장/개선용으로 실제로 효과적임을 실험적으로 증명
Learning Interpretable Features in Audio Latent Spaces via Sparse Autoencoders	Nathan Paek ^{3†‡} , Yongyi Zang ^{1‡} , Qihui Yang ^{2†‡} , Randal Leistikow	arXiv preprint	Sparse Autoencoder를 활용해 오디오 생성 모델의 잠재 공간에서 사람에게 해석 가능한 음향 개념 (피치·음색·음량) 기반 특징을 학습 분석하는 방법을 제안함

Appendix

Whisper의 기본 설정:

- 샘플링 레이트: 16 kHz
- window length: 25 ms
- hop length: 10 ms



<https://cdn.openai.com/papers/whisper.pdf>