

Mitigating Interviewer Bias in Multimodal Depression Detection: An Approach with Adversarial Learning and Contextual Positional Encoding

Enshi Zhang, Christian Poellabauer Knight Foundation School of Computing & Information Sciences Florida International University, Miami, FL 33199, USA {ezhan004, cpoellab}@fiu.edu

2026.03.20
junghyorin

Index

1. Motivation
2. Key Idea
3. Methods
 - a. Feature Extraction
 - b. Depression Detection
4. Experiments
 - a. Data Augmentation and Preprocessing
 - b. Implementation Details
 - c. Evaluation
 - d. Baseline and Ablations
5. Results and Discussion

Motivation

논문에서 직접 말하는 포인트:

- 모델이 **participant** 답변이 아니라 **interviewer** 질문 패턴을 학습
- 특정 질문 자체가 이미 우울 여부 힌트를 포함

예시: “Has your mental health improved?” → 이 질문 자체가 이미 상태를 암시

이 논문이 가져온 Bias 핵심 선행 근거:

DAIC-WOZ: On the Validity of Using the Therapist’s prompts in Automatic Depression Detection from Clinical Interviews / Clinical NLP Workshop (NAACL 2024)

- interviewer 질문만 써도 높은 성능 나옴 → 모델이 질문에 의존 → 모델이 **shortcut** 학습
- 뒤에 Ablation으로 증명 (인터뷰+텍스트+오디오 조합)

Key Idea

목표: Interviewer bias 제거 + 진짜 환자 신호 학습

해결 전략

1. 대화 전체 흐름 이해 (Dialogue-level modeling)
2. 질문 영향 제거 (Adversarial learning)

Framework

입력 (Input)

- 질문 Q_j : interviewer 질문 (text)
- 응답 A_j :
 - $A_j\text{text}$: 응답 텍스트 (transcribed text)
 - $A_j\text{audio}$: 음성 (speech signal)

$$I = \{(Q_1, A_1), \dots, (Q_k, A_k)\}$$

👉 인터뷰 = QA sequence

Feature Extraction

Text Encoding

- 모델: XLM-RoBERTa(multilingual 데이터 대응)
- 처리과정:
 - 문장 → 토큰화 >> Transformer encoder 통과 >> 각 토큰 → 768차원 벡터 >> mean pooling
- 출력: 768-d vector

Audio Encoding

- 모델: Wav2Vec2-XLSR (raw audio → representation 학습 # self supervised speech encoder)
- raw audio 입력 (16kHz) >> frame-level embedding 생성 (frame 1024차원) >> temporal mean pooling
- Audio Projection
 - 출력: 1024 → 768 projection (텍스트와 합치기 위해) $a_i^{\text{audio}} = W_{\text{proj}} \cdot a_i^{\text{raw}} + b$

Multimodal Fusion

- 각 modality의 중요도를 gate(0~1)로 학습
- 중요한 정보는 강조, 불필요한 정보는 억제
- 방법 (Gated Fusion)
 - 2 layer MLP + Relu
- 출력:

$$h_q = \text{MLP}_q(q_j^{\text{text}})$$

$$h_t = \text{MLP}_t(a_j^{\text{text}})$$

$$h_a = \text{MLP}_a(a_j^{\text{audio}})$$

$$z_j = g_q \odot h_q + g_t \odot h_t + g_a \odot h_a$$

text ┐

└─> gate → weighted sum → z

audio ┌

Contextual Positional Encoding

기존 positional encoding의 한계

- 기존 positional encoding은 순서 정보만 반영
- 하지만 임상 인터뷰에서는 같은 3번째 turn이라도 질문 의미가 다름

CoPE의 한계

- 원래 CoPE는 token-level context를 반영하는 방식
- 그러나 이 논문은 turn-level dialogue를 다룸
- 따라서 단어 수준이 아니라 QA turn 수준의 contextual position이 필요

Dialogue-based Contextual Positional Encoding (D-CoPE)

Dialogue-based Contextual Positional Encoding (D-CoPE).

- turn position
 - 현재 QA pair가 인터뷰에서 몇 번째인지
- question semantics
 - interviewer의 질문이 어떤 의미/맥락을 가지는지

D-CoPE 생성 과정

Step 1. 위치 정보 생성

$$p_j \in \mathbb{R}^{768}$$



Step 2. 질문 의미 벡터 생성

$$qc_j = \text{MLP}_{\text{CoPE}}(q_j^{\text{text}})$$



Step 3. 두 정보 결합

$$c_j = W_{\text{CoPE}}[p_j; qc_j] + b_{\text{CoPE}}$$

Step 4. multimodal fused feature에 더함



$$z'_j = z_j + c_j$$

Dialogue-level Transformer

- QA turn 간 관계 학습
- 전체 대화 맥락 반영

입력

$$Z' \in \mathbb{R}^{k \times 768}$$


처리

$$H = \text{TransformerEncoder}(Z')$$

출력

(전체 대화를 고려한 contextual representation)

$$H_j$$



Depression Detection

- Attention Pooling
- Prediction
 - MLP (2-layer)
- Tasks
 - Classification (BCE loss)
 - Regression (MSE loss)

$$H_{\text{global}} = \sum_{j=1}^{T_k} \alpha_j H_j$$

Prompt Label Prediction

- 7 categorize prompts(QFs):
 - 'open-ended', 'change talk', 'neutral information gathering', 'transitional', 'specific probing', 'supportive', and 'other'
 - Using LLM
- 입력: Transformer 출력 H_j
 - main task (depression)
 - adversary (QF prediction)
- GRL (Gradient Reversal Layer)
 - forward: 그대로 전달
 - backward: gradient 반전
- $\mathcal{L}_{\text{main}}$: 우울 예측 → 성능 향상
- $\mathcal{L}_{\text{adv}}$: 예측 → 제거 유도

$$\hat{T}_j = \text{MLP}_{\text{adv}}(\text{GRL}(H_j))$$

👉 질문은 못 맞추게, 우울은 잘 맞추게 학습됨 $\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{main}} - \lambda \cdot \mathcal{L}_{\text{adv}}$

Experimental Setup

Datasets

1. DAIC-WOZ (영어)

- 189명 인터뷰
- 57 depressed / 132 healthy
- 16kHz audio + text + visual
- PHQ-8 기준 라벨

2. EATD (중국어)

- 162명
- 30 depressed / 132 healthy
- audio + text
- SDS 기준

3. Androids (이탈리아어)

- 116명
- 62 depressed / 54 healthy
- DSM-5 기준

Experimental Setup

Data Imbalance & Augmentation

1. Oversampling

- DAIC-WOZ → minority class (depressed) 복제
- EATD → QA pair 순서 재배열
- Androids → 이미 균형 → 적용 안함

2. Synthetic Data

- LLM (GPT-4o) 사용
- 질문은 유지
- 답변만 새로 생성
 - 텍스트 생성: 의미 유지 + 표현만 변경
 - 오디오 생성: 기존 audio → frame swapping

Implementation Details

환경

- Framework: PyTorch
- GPU: NVIDIA A100 (40GB)
- Platform: Google Colab Pro

학습 설정

- Batch size: 8
- Epochs: 20
- Optimizer: AdamW
- Learning rate: $1e-3$

Evaluation

- Cross-Validation
 - 5-fold stratified cross-validation 사용 > 최종 결과는 5번 실험 결과 평균 사용
 - 각 fold는 동일한 class 비율 유지
- Evaluation Metrics
 - Classification (우울 여부)
 - F1 score → precision + recall 균형
 - AUC-ROC → 전체 threshold에서 분류 성능
 - Regression (우울 정도)
 - RMSE → 큰 오차에 민감
 - MAE → 평균적인 오차 크기

Baseline and Ablations

Baseline 비교 (3가지 관점)

1. 질문 포함 모델: interviewer 질문 + participant 응답 사용
2. 질문 제외 모델: participant 정보만 사용 (text/audio)
3. 질문만 사용하는 모델 : interviewer 질문만 사용

Ablation Study (2가지)

1. 모델 구조 ablation

- D-CoPE 제거
- Adversarial 제거

2. modality ablation

- text만
- audio만
- multimodal

Results and Discussion

I: 면담자의 질문 텍스트 (Interviewer text)

A: 참가자의 음성 오디오 (Participant audio)

T: 참가자의 응답 텍스트 (Participant transcribed text)

V: 시각적 특징 (Visual features)

Model	Modality	DAIC-WOZ		EATD		Androids		DAIC-Synthetic	
		F1	RMSE	F1	RMSE	F1	RMSE	F1	RMSE
GCN-PE (Burdisso et al., 2024)	I	0.84	4.51	0.55	5.94	0.59	–	0.84	4.45
WU (Wu et al., 2023)	A + T	0.80	<u>4.36</u>	0.67	4.21	0.71	–	0.81	<u>4.29</u>
MMPF (Yang et al., 2024)	A + T	0.76	5.11	0.66	4.46	0.70	–	0.78	5.02
ACMA (Iyortsuun et al., 2024)	A + T	0.69	5.15	0.61	5.12	0.68	–	0.72	4.80
LLM (Zhang et al., 2024)	A + T	0.76	5.04	0.64	4.68	0.69	–	0.79	4.61
CAMFM (Xue et al., 2024)	A + T	0.80	4.71	<u>0.70</u>	<u>4.10</u>	<u>0.72</u>	–	0.81	4.51
DAI (Dai et al., 2021)	I + A + T + V	0.81	4.67	0.67	4.33	0.71	–	0.80	4.65
HCAG (Niu et al., 2021)	I + A + T	0.80	4.79	0.65	5.54	0.69	–	0.81	4.43
SHEN (Shen et al., 2022)	I + A + T + V	0.77	5.25	0.68	4.59	0.70	–	0.77	5.14
MILI (Milintsevich et al., 2023)	I + T	0.75	5.11	0.62	5.97	0.68	–	0.76	4.96
SEGA (Chen et al., 2024)	I + A + T + V	0.71	5.04	<u>0.70</u>	4.93	0.70	–	0.74	4.90
GCN (Burdisso et al., 2023)	I + T	0.79	4.95	0.61	5.52	0.69	–	0.80	4.87
AGAR (Agarwal et al., 2024)	I + T	0.72	5.96	0.58	5.53	0.67	–	0.72	5.91
Dialogue Transformer (ours)	I + A + T	<u>0.82</u>	3.86	0.72	4.04	0.73	–	<u>0.83</u>	3.84

Table 1: Results from training and testing on each dataset individually. *A*, *T*, and *V* refer to participant audio, transcribed text, and visual features; *I* denotes interviewer prompts (text). Best results are in **bold**, second-best are underlined, and – indicates unavailable data. Higher F1 and lower RMSE indicate better performance.

Model Variant	Modality	DAIC-WOZ		EATD		Androids		DAIC-Synthetic	
		F1	RMSE	F1	RMSE	F1	RMSE	F1	RMSE
D-CoPE + QF + GRL (Full Model)	I + A + T	0.82	<u>3.86</u>	0.72	<u>4.04</u>	0.73	–	0.83	3.84
D-CoPE + QF	I + A + T	0.89	3.81	<u>0.71</u>	4.12	0.70	–	0.90	<u>3.82</u>
D-CoPE + GRL	I + A + T	<u>0.83</u>	<u>3.86</u>	0.72	4.01	0.73	–	<u>0.84</u>	3.74
QF + GRL	I + A + T	0.65	5.41	0.54	4.90	0.58	–	0.63	5.37
Base Model	I + A + T	0.65	5.57	0.53	4.95	0.57	–	0.67	5.40
Full Model	I + A	0.70	4.52	0.61	5.38	0.63	–	0.74	4.31
Full Model	I + T	0.77	4.34	0.65	4.99	0.66	–	0.79	4.19
Full Model	A + T	0.70	4.50	0.70	4.17	0.65	–	0.72	4.56

모달리티 별 기여도 실험

Table 2: Ablation study results for depression detection across four datasets. **D-CoPE** refers to our proposed Dialogue-based Contextual Positional Encoding. **QF** indicates the use of Interviewer Question Function labels as targets for the adversarial classifier, and **GRL** refers to the Gradient Reversal Layer used in the adversarial training. ‘Base Model’ lacks all three of these components but uses the same underlying multimodal architecture. *I*, *A*, and *T* represent the interviewer’s prompt in text format, the participant’s response in audio, participant’s response in text, respectively.

Limitations

- Data Limitations

- 데이터 규모 부족 → 임상 음성 데이터는 작고 접근 제한 존재
- 데이터 불균형 및 제한적 다양성 → **oversampling & synthetic data**로 보완
- 모달리티 제한 (**text + audio** 중심) → **video / physiological data** 미포함

- Model Limitations

- **dyadic clinical interview**에 최적화
→ **monologue / self-report**에는 적용 어려움

- IQF(label) 의존성

- LLM 기반 자동 라벨링 사용 → 실제 **interviewer** 행동을 완전히 반영하지 못할 수 있음
- 기준 자체가 틀릴 수도 있음




Figure 3: Use LLM to generate synthetic data by rephrasing responses from participants for each question-answer pair.

Model	Modality	DAIC-WOZ		EATD		Androids		DAIC-Synthetic	
		AUC-ROC	MAE	AUC-ROC	MAE	AUC-ROC	MAE	AUC-ROC	MAE
GCN-PE (Burdisso et al., 2024)	I	0.89	4.06	0.60	5.35	0.64	–	0.88	4.00
WU (Wu et al., 2023)	A + T	0.84	3.90	0.71	3.79	0.77	–	0.85	3.86
MMPF (Yang et al., 2024)	A + T	0.81	4.60	0.73	4.01	0.76	–	0.82	4.52
ACMA (Iyortsuun et al., 2024)	A + T	0.76	4.64	0.69	4.61	0.72	–	0.74	4.32
LLM (Zhang et al., 2024)	A + T	0.80	4.54	0.70	4.21	0.74	–	0.83	4.15
CAMFM (Xue et al., 2024)	A + T	0.84	4.24	0.77	3.69	0.76	–	0.85	4.06
DAI (Dai et al., 2021)	I + A + T + V	0.84	4.20	0.72	3.90	0.77	–	0.83	4.18
HCAG (Niu et al., 2021)	I + A + T	0.85	4.31	0.70	4.98	0.75	–	0.79	3.99
SHEN (Shen et al., 2022)	I + A + T + V	0.80	4.72	0.77	4.13	0.72	–	0.80	4.63
MILI (Milintsevich et al., 2023)	I + T	0.82	4.60	0.65	5.37	0.70	–	0.79	4.46
SEGA (Chen et al., 2024)	I + A + T + V	0.80	4.54	0.77	4.44	0.74	–	0.79	4.41
GCN (Burdisso et al., 2023)	I + T	0.84	4.46	0.69	4.97	0.72	–	0.82	4.38
AGAR (Agarwal et al., 2024)	I + T	0.80	5.36	0.66	4.98	0.75	–	0.80	5.32
Dialogue Transformer (ours)	I + A + T	0.89	3.47	0.75	3.64	0.80	–	0.90	3.46

Table 3: Best results are in **bold**, and – indicates unavailable data. Higher AUC-ROC and lower MAE indicate better performance.

Train \ Test	DAIC-WOZ				EATD				Androids				DAIC-Synthetic			
	F1	RMSE	AUC-ROC	MAE	F1	RMSE	AUC-ROC	MAE	F1	RMSE	AUC-ROC	MAE	F1	RMSE	AUC-ROC	MAE
DAIC-WOZ	0.82	3.86	0.89	3.47	0.67	4.47	0.74	4.10	0.72	4.20	0.79	3.87	–	–	–	–
EATD	0.61	5.22	0.69	4.78	0.72	4.04	0.75	3.64	0.59	5.10	0.65	4.59	0.61	5.25	0.68	4.97
Androids	0.70	–	0.77	–	0.66	–	0.72	–	0.73	–	0.80	–	0.69	–	0.76	–
DAIC-Synthetic	–	–	–	–	0.68	4.40	0.74	3.96	0.74	4.10	0.78	3.66	0.83	3.84	0.90	3.46

Table 4: Cross-dataset validation results.

bias 검증 방법

- 동일한 모델에서 입력만 바꿔 **participant-only**와 **therapist-only**로 나눠 비교
- **Longformer** 기반 모델과 **GCN** 모델을 사용해 구조에 따른 영향도 함께 확인
 - P-longBERT
 - E-longBERT
 - P-GCN
 - E-GCN
- **therapist-only** 성능을 통해 질문 자체에 분류 신호가 있는지 검증했음
- 두 모델 결과를 결합해 질문과 응답이 성능에 어떻게 기여하는지도 확인했음
 - 결론: 두 모델 모두 **therapist-only** 성능 높 -> 모델 구조가 아닌 데이터 자체의 편향 발견

bias 발생 위치 추적 방법

- GCN을 이용해 우울 판단에 사용된 단어를 추출하고 분석했음
- 단어들이 인터뷰 어느 구간에 집중되는지 **heatmap**으로 시각화했음
- **therapist** 기반 단서는 인터뷰 후반 특정 질문 구간에 집중되는 패턴을 보였음
- 인터뷰를 앞/뒤로 나눠 실험하여 후반부 질문 의존성을 추가로 검증했음

